Predição de Consumo Energético e Classificação de Perfis de Condução em Veículos Elétricos Utilizando Aprendizado de Máquinas

Danilo Carvalho de Oliveira[1]; Douglas Donizeti de Castilho Braz[2]

Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas - Campus Poços de Caldas - CEP 37.713-100 – Poços de Caldas – MG – Brasil

danilo.carvalho@alunos.ifsuldeminas.edu.br [1]; douglas.braz@ifsuldeminas.edu.br [2]

Resumo:

Este trabalho propõe a aplicação de técnicas de aprendizado de máquinas para classificação de perfis de condução por meio de métodos não supervisionados e a predição do consumo energético por meio de algoritmos de regressão supervisionada em veículos elétricos. Para a realização dos experimentos será utilizado o *Vehicle Energy Dataset (VED)*, composto por dados reais de operação veicular. Na primeira etapa, serão aplicadas técnicas de clusterização para identificar e caracterizar padrões de comportamento dos motoristas a partir de variáveis operacionais. Na segunda etapa, serão desenvolvidos e comparados modelos de regressão: regressão linear, *Random Forest Regressor* e redes neurais do tipo *MLP Regressor* para estimativa do consumo energético. Espera-se identificar a influência de variáveis como velocidade, aceleração, perfil de condução e características do trajeto sobre o consumo energético em veículos elétricos para o desenvolvimento de soluções voltadas à eficiência energética na mobilidade elétrica.

*Palavras-chave: **Aprendizado de Máquinas; Veículos Elétricos; Consumo Energético; Análise de Dados; Clusterização.**

1. Introdução

A eletrificação da frota veicular tem avançado de forma expressiva nos últimos anos. Segundo a Agência Internacional de Energia (IEA, 2024), o número de veículos elétricos em circulação no mundo ultrapassou 40 milhões de unidades em 2023, com projeções de crescimento contínuo impulsionadas por políticas de descarbonização e redução de custos das baterias. No Brasil, o segmento ainda está em fase inicial, mas registrou crescimento superior a 80% nas vendas entre 2022 e 2023, sinalizando uma tendência de adoção crescente (ABVE, 2024).

Nesse contexto, a autonomia de carga é apontada como um dos principais fatores que influenciam a decisão de compra e a experiência de uso dos veículos elétricos (MADZIEL; CAMPISI, 2023). A capacidade de prever com precisão o consumo energético a partir de variáveis operacionais em tempo real é, portanto, um problema de relevância prática e científica. Diferentemente dos motores de combustão interna, cujo comportamento pode ser modelado por parâmetros mais estáveis, os veículos elétricos apresentam alta sensibilidade a fatores dinâmicos como velocidade, aceleração, regeneração de energia e condições do percurso (DI MARTINO *et al*., 2022).

Paralelamente, o comportamento do motorista constitui uma dimensão relevante na análise de dados veiculares. A identificação de padrões de condução a partir de dados operacionais é um problema de classificação com aplicações práticas em seguros veiculares, programas de condução eficiente e sistemas de assistência ao motorista (MOBINI SERAJI *et al*., 2025). Estudos mostram que é possível distinguir estilos de condução distintos, como conduta agressiva, moderada e econômica, de forma automatizada, com base em variáveis como aceleração, frenagem e velocidade média (RISTIANA *et al*., 2019).

Para a realização dos experimentos será utilizado o *VED*, uma base de dados composta por informações reais de operação veicular que reúne variáveis relevantes para a análise do comportamento de condução e do consumo energético (OH *et al*., 2020).

Diante desse cenário, este trabalho aborda dois problemas sobre o mesmo conjunto de dados. Na primeira parte, serão aplicadas técnicas de aprendizado não supervisionado para classificar perfis de condução. Na segunda parte, serão desenvolvidos e comparados modelos de regressão supervisionada para predição do consumo energético dos veículos. O trabalho está estruturado da seguinte forma: a Seção 2 apresenta os objetivos; a Seção 3 discute a fundamentação teórica; a Seção 4 descreve a metodologia; a Seção 5 apresenta os resultados esperados.

2. Objetivos

Esta seção apresenta os objetivos que orientam o desenvolvimento deste trabalho, bem como as questões de pesquisa que motivam a investigação proposta. A partir da análise de dados reais de operação veicular, busca-se compreender a relação entre o comportamento de condução e o consumo energético em veículos elétricos, utilizando técnicas de aprendizado de máquinas para apoiar essa análise.

2.1 Perguntas de Pesquisa

Com o intuito de direcionar o desenvolvimento da pesquisa, foram definidas as seguintes questões:

- É possível identificar perfis distintos de condução a partir de dados reais de operação veicular utilizando técnicas de aprendizado de máquinas?
- Quais variáveis apresentam maior influência na estimativa do consumo energético dos veículos analisados?

2.2 Objetivos Gerais

Este trabalho tem como objetivo geral aplicar técnicas de aprendizado de máquinas para identificar e classificar perfis de condução por meio de técnicas de clusterização, bem como desenvolver e avaliar modelos preditivos capazes de estimar o consumo energético em veículos elétricos a partir de dados reais de operação veicular.

2.3 Objetivos Específicos

Para atingir os objetivos gerais propostos, foram definidos os seguintes objetivos específicos, que representam as etapas necessárias para o desenvolvimento da pesquisa:

- Analisar a estrutura e as características do *VED*, identificando variáveis relevantes para cada uma das duas tarefas propostas;
- Realizar o pré-processamento dos dados, incluindo tratamento de valores ausentes, remoção de ruídos e normalização;
- Construir atributos derivados representativos do comportamento de condução, como variação de velocidade, frequência de frenagem e padrões de aceleração;
- Aplicar algoritmos de clusterização para identificação e caracterização dos perfis de condução presentes no *dataset*, avaliando a coesão e separação dos grupos obtidos;
- Implementar e comparar modelos de regressão supervisionada: regressão linear, *Random Forest* e redes neurais artificiais para predição do consumo energético;
- Avaliar o desempenho dos modelos preditivos por meio das métricas *MAE*, *RMSE* e R^2, identificando qual abordagem apresenta melhor resultado para o problema proposto.

3. Fundamentação Teórica

Esta seção apresenta os principais conceitos teóricos relacionados ao consumo energético em veículos elétricos, ao uso de técnicas de aprendizado de máquinas para predição e à classificação de perfis de condução, fornecendo a base conceitual necessária para o desenvolvimento do trabalho.

3.1 Consumo Energético em Veículos Elétricos

O consumo energético em veículos elétricos resulta da interação entre fatores técnicos, ambientais e operacionais. Do ponto de vista técnico, a eficiência do motor elétrico, a capacidade da bateria e o sistema de frenagem regenerativa exercem influência direta sobre a demanda energética. Do ponto de vista externo, variáveis como a declividade da via, as condições de tráfego e a temperatura ambiente também afetam o consumo de forma significativa (DI MARTINO *et al*., 2022). Madziel e Campisi (2023) complementam essa visão ao demonstrar, com base em dados de campo, que o consumo real de veículos elétricos pode divergir em até 40% dos valores declarados pelos fabricantes em condições urbanas de uso intenso.

Uma revisão sistemática conduzida por Di Martino *et al*. (2022) categoriza as estratégias de modelagem do consumo energético em três abordagens: modelos físicos baseados em equações cinemáticas, modelos estatísticos e modelos baseados em aprendizado de máquinas. Os autores concluem que abordagens baseadas em dados apresentam vantagens em cenários de alta variabilidade, onde as relações entre variáveis são não lineares e difíceis de modelar analiticamente, exatamente o caso do comportamento em tráfego urbano real.

3.2 Predição de Consumo com Aprendizado de Máquinas

A aplicação de algoritmos de aprendizado de máquinas à predição de consumo energético veicular tem crescido de forma expressiva na literatura recente. Foram avaliadas diferentes abordagens para estimativa de consumo em veículos elétricos utilizando dados de sensores embarcados, com destaque para modelos de *Gradient Boosting* e redes

neurais, que obtiveram resultados superiores aos modelos físicos tradicionais especialmente em condições urbanas de tráfego variável (Achariyaviriya *et al*., 2023). Os autores apontam que a granularidade temporal dos dados de entrada é um fator crítico: modelos treinados com amostras de 1 Hz apresentaram desempenho consistentemente superior aos treinados com dados agregados por minuto.

Em um estudo comparativo mais amplo, Hussain *et al*. (2025) avaliaram sete algoritmos aplicados à predição de consumo energético em veículos elétricos. Os resultados indicaram que o *Random Forest* obteve o melhor desempenho geral, com R^2 superior a 0,93 e *RMSE* reduzido em aproximadamente 38% em relação à regressão linear. Os autores destacam que a qualidade do pré-processamento e a seleção de atributos foram determinantes para a diferença de desempenho entre os algoritmos testados. Jui *et al*. (2024) reforçam essa perspectiva ao apontar que modelos com engenharia de atributos orientada ao comportamento operacional do veículo tendem a generalizar melhor para novos percursos.

3.3 Classificação de Perfis de Condução

A identificação de padrões de comportamento de motoristas a partir de dados veiculares é um problema bem estabelecido na literatura. Ristiana *et al*. (2019) demonstraram que variáveis como aceleração média, variação de velocidade e frequência de eventos bruscos de frenagem são suficientes para distinguir estilos de condução com algoritmos de clusterização, obtendo separação estatística significativa entre grupos mesmo em *datasets* de dimensão reduzida. O algoritmo *K-Means* tem sido amplamente adotado nesse contexto pela sua eficiência computacional e pela interpretabilidade direta dos centróides resultantes (CHEN *et al*., 2023).

Uma revisão abrangente conduzida por Mobini Seraji *et al*. (2025), cobrindo mais de 120 trabalhos publicados entre 2015 e 2024, consolidou o estado da arte em técnicas de classificação comportamental de condutores. Os autores identificaram que a maioria dos estudos converge para três ou quatro perfis distintos, tipicamente denominados condução econômica, moderada e agressiva, e que esses perfis apresentam consistência estatística robusta quando derivados de janelas temporais superiores a cinco minutos. A revisão também destaca que métodos baseados em densidade, como o *DBSCAN*, têm ganhado espaço como alternativa ao *K-Means* em *datasets* com ruídos significativos. Chen *et al*. (2023), por sua vez, demonstraram que perfis derivados de dados de trajetória apresentam correlação significativa com indicadores de risco veicular, evidenciando a utilidade prática dessa classificação além da análise energética.

4. Metodologia

Este trabalho caracteriza-se como uma pesquisa aplicada de natureza experimental, baseada em dados reais de operação veicular. A metodologia está organizada em duas frentes: classificação de perfis de condução e predição de consumo energético, que compartilham o mesmo *dataset* e as etapas iniciais de pré-processamento. A sequência de etapas proposta para o desenvolvimento deste trabalho é apresentada na Figura 1.

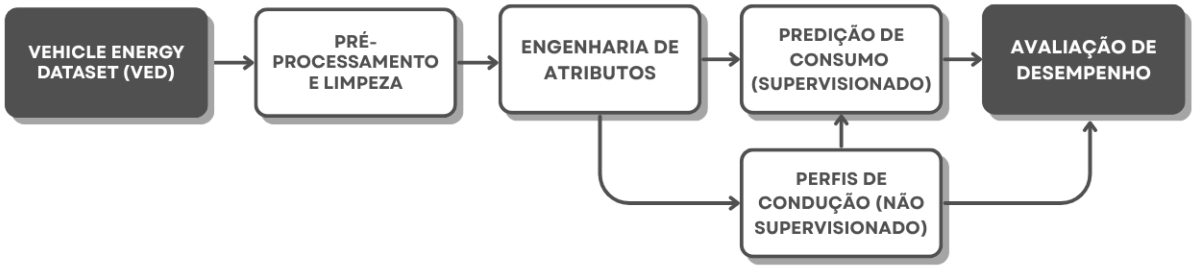


Figura 1: Fluxo metodológico proposto para o trabalho

4.1 Tecnologias Utilizadas

Para o desenvolvimento deste trabalho, serão utilizadas ferramentas e tecnologias voltadas à análise de dados e aplicação de modelos de aprendizado de máquinas. A linguagem de programação principal será o Python, devido à sua ampla utilização em projetos de ciência de dados e aprendizado de máquinas.

Serão utilizadas bibliotecas específicas para manipulação e análise de dados, como Pandas e NumPy, além de bibliotecas para visualização, como Matplotlib e Seaborn. Para a implementação dos modelos de aprendizado de máquinas, será utilizada a biblioteca Scikit-learn, que oferece suporte a diversos algoritmos de classificação e regressão. Caso necessário, também poderão ser utilizadas bibliotecas como TensorFlow ou Keras para implementação de redes neurais artificiais.

4.2 Base de Dados Utilizada

Para o desenvolvimento deste trabalho será utilizado o *VED*, um conjunto de dados público disponibilizado para pesquisas relacionadas à análise de veículos, comportamento de condução e consumo energético. A base reúne dados reais coletados durante a operação de diferentes veículos em condições reais de tráfego, contendo informações provenientes de sensores veiculares e dispositivos de posicionamento global (GPS).

O *dataset* disponibiliza variáveis relevantes para a análise proposta neste trabalho, incluindo velocidade instantânea, aceleração, posição geográfica (latitude e longitude), distância percorrida, tempo de viagem e informações relacionadas ao consumo energético dos veículos. Além disso, os dados estão organizados em arquivos contendo registros temporais detalhados, possibilitando a análise do comportamento dos condutores ao longo de diferentes trajetos.

A escolha do *VED* justifica-se pela disponibilidade de atributos diretamente relacionados aos objetivos da pesquisa, permitindo tanto a identificação de perfis de condução quanto a modelagem do consumo energético. A presença de variáveis comportamentais, como velocidade e aceleração, possibilita a extração de características associadas ao estilo de condução dos motoristas, enquanto os dados de consumo energético permitem o desenvolvimento e avaliação dos modelos preditivos.

Inicialmente, será realizada uma etapa de análise exploratória para compreender a estrutura dos dados, identificar possíveis inconsistências e selecionar os atributos mais

relevantes para o estudo. Em seguida, serão executadas etapas de pré-processamento, incluindo tratamento de valores ausentes, remoção de registros inconsistentes e normalização dos dados, visando garantir a qualidade das informações utilizadas pelos algoritmos de aprendizado de máquinas.

A utilização de uma base de dados real contribui para aumentar a confiabilidade dos resultados obtidos e aproxima o estudo de cenários encontrados em aplicações práticas, permitindo avaliar o potencial das técnicas propostas em condições representativas de uso de veículos elétricos.

4.3 Arquitetura do Sistema

A metodologia proposta neste trabalho será dividida em etapas, desde a coleta dos dados até a avaliação dos modelos de aprendizado de máquinas.

Será realizada a etapa de engenharia de atributos, com o objetivo de extrair características relevantes relacionadas ao comportamento de condução, como variação de velocidade, padrões de aceleração e frequência de frenagem.

Posteriormente, será aplicada uma técnica de aprendizado não supervisionado, como o algoritmo *K-Means*, para identificação de perfis de condução. Esses perfis serão interpretados e classificados em categorias como condução agressiva, moderada ou econômica.

Em seguida, os perfis identificados serão incorporados como variáveis adicionais no conjunto de dados, sendo utilizados como entrada para os modelos de aprendizado supervisionado. Serão implementados diferentes algoritmos de regressão, como regressão linear, *Random Forest* e redes neurais artificiais, com o objetivo de prever o consumo energético dos veículos.

Por fim, os modelos serão avaliados utilizando métricas de desempenho como erro absoluto médio (*MAE*), raiz do erro quadrático médio (*RMSE*) e coeficiente de determinação (R^2). Também será realizada uma análise comparativa entre os modelos, bem como uma avaliação do impacto da inclusão dos perfis de condução na precisão das previsões.

4.4 Cronograma de Atividades

Tabela 1 - Cronograma de Atividades

	CRONOGRAMA DO TRABALHO FINAL DE CONCLUSÃO DE CURSO				
ETAPAS	**AGO/2026**	**SET/2026**	**OUT/2026**	**NOV/2026**	**DEZ/2026**
Levantamento bibliográfico	**X**				
Estudo do dataset (*VED*)	**X**				
Limpeza e tratamento de dados	**X**	**X**			
Engenharia de atributos		**X**			
Desenvolvimento (modelos ML)		**X**	**X**		

Clusterização (perfil)		**X**			
Integração dos modelos			**X**		
Testes e avaliação			**X**	**X**	
Escrita do artigo				**X**	
Revisão final				**X**	
Defesa do TCC					**X**

5. Resultados Esperados

Espera-se que o desenvolvimento deste trabalho permita a construção de modelos de aprendizado de máquinas capazes de prever o consumo energético em veículos elétricos com boa precisão, utilizando dados reais de operação veicular. A partir da aplicação de diferentes algoritmos de regressão, como regressão linear, *Random Forest* e redes neurais artificiais, espera-se identificar quais abordagens apresentam melhor desempenho na tarefa proposta.

Além disso, espera-se que a aplicação de técnicas de aprendizado não supervisionado possibilite a identificação de diferentes perfis de condução a partir dos dados do *VED*. Esses perfis deverão representar padrões distintos de comportamento, como condução agressiva, moderada ou econômica, sendo obtidos a partir da análise de variáveis como velocidade e aceleração.

Outro resultado esperado é a verificação da influência dos perfis de condução na predição do consumo energético. Ao incorporar essas informações como variáveis adicionais nos modelos, espera-se observar melhorias nos indicadores de desempenho, como redução do erro absoluto médio (*MAE*) e da raiz do erro quadrático médio (*RMSE*), além do aumento do coeficiente de determinação (R^2).

Espera-se também que os resultados obtidos permitam uma análise comparativa entre os modelos implementados, possibilitando identificar quais técnicas são mais adequadas para o problema estudado. Essa análise poderá contribuir para a compreensão das relações entre comportamento de condução e consumo energético.

Por fim, espera-se que o trabalho contribua para o desenvolvimento de soluções voltadas à eficiência energética em veículos elétricos, fornecendo subsídios para futuras pesquisas e aplicações práticas no contexto de sistemas inteligentes e mobilidade elétrica.

6. Referências Bibliográficas

ACHARIYAVIRIYA, Witsarut et al. Estimating energy consumption of battery electric vehicles using vehicle sensor data and machine learning approaches. **Energies**, v. 16, n. 17, p. 6351, 2023.

ASSOCIAÇÃO BRASILEIRA DO VEÍCULO ELÉTRICO (ABVE). 94 mil eletrificados: 2023 bate todas as previsões. São Paulo: ABVE, 2024. Disponível em: https://abve.org.br/2023-supera-todas-as-previsoes-94-mil-eletrificados/. Acesso em: 15 junho 2026.

CHEN, Shuyi et al. Driving behavior risk measurement and cluster analysis driven by vehicle trajectory data. **Applied Sciences**, v. 13, n. 9, p. 5675, 2023.

DI MARTINO, Andrea; MIRAFTABZADEH, Seyed Mahdi; LONGO, Michela. Strategies for the modelisation of electric vehicle energy consumption: A review. **Energies**, v. 15, n. 21, p. 8115, 2022.

HUSSAIN, Izhar et al. Evaluating machine learning algorithms for energy consumption prediction in electric vehicles: A comparative study. **Scientific Reports**, v. 15, n. 1, p. 16124, 2025.

INTERNATIONAL ENERGY AGENCY (IEA). Perspectivas Globais para Veículos Elétricos 2024. Paris: IEA, 2024. Disponível em: https://www.iea.org/reports/global-ev-outlook-2024/trends-in-electric-cars. Acesso em: 15 junho 2026.

JUI, Julakha Jahan et al. Optimal energy management strategies for hybrid electric vehicles: A recent survey of machine learning approaches. **Journal of Engineering Research**, v. 12, n. 3, p. 454-467, 2024.

KAKOUCHE, Khoudir et al. Model predictive direct torque control and fuzzy logic energy management for multi power source electric vehicles. **Sensors**, v. 22, n. 15, p. 5669, 2022.

MĄDZIEL, Maksymilian; CAMPISI, Tiziana. Energy consumption of electric vehicles: Analysis of selected parameters based on created database. **Energies**, v. 16, n. 3, p. 1437, 2023.

MOBINI SERAJI, Mohammad Hassan et al. A state-of-the-art review on machine learning techniques for driving behavior analysis: clustering and classification approaches. **Complex & Intelligent Systems**, v. 11, n. 9, p. 386, 2025.

OH, Geunseob; LEBLANC, David J.; PENG, Huei. Vehicle energy dataset (VED), a large-scale dataset for vehicle energy consumption research. **IEEE Transactions on Intelligent Transportation Systems**, v. 23, n. 4, p. 3302-3312, 2020.

RISTIANA, Rina et al. A new approach of EV modeling and its control applications to reduce energy consumption. **IEEE Access**, v. 7, p. 141209-141225, 2019.