

Predição de Consumo Energético e Classificação de Perfis de Condução em Veículos Elétricos Utilizando Aprendizado de Máquina

Danilo Carvalho de Oliveira¹; Douglas Donizeti de Castilho Braz²

Instituto Federal de Educação, Ciência e Tecnologia do Sul de Minas - Campus Poços de Caldas - CEP 37.713-100 – Poços de Caldas – MG – Brasil

danilo.carvalho@alunos.ifsuldeminas.edu.br ¹; douglas.braz@ifsuldeminas.edu.br ²

Resumo:

Este trabalho propõe a aplicação de técnicas de aprendizado de máquina a dois problemas no contexto de veículos elétricos, utilizando como base o Vehicle Energy Dataset (VED): a classificação de perfis de condução por meio de métodos não supervisionados e a predição do consumo energético por meio de algoritmos de regressão supervisionada. Na primeira etapa, serão aplicadas técnicas de clusterização para identificar e caracterizar padrões de comportamento dos motoristas a partir de variáveis operacionais. Na segunda etapa, serão desenvolvidos e comparados modelos de regressão — regressão linear, Random Forest e redes neurais artificiais — para estimativa do consumo energético. Espera-se que os resultados contribuam para a compreensão dos fatores que influenciam o consumo em veículos elétricos e para o desenvolvimento de soluções voltadas à eficiência energética na mobilidade elétrica.

*Palavras-chave: **Aprendizado de Máquina; Veículos Elétricos; Consumo Energético; Análise de Dados; Clusterização.**

1. Introdução

A eletrificação da frota veicular tem avançado de forma expressiva nos últimos anos. Segundo a Agência Internacional de Energia (IEA, 2024), o número de veículos elétricos em circulação no mundo ultrapassou 40 milhões de unidades em 2023, com projeções de crescimento contínuo impulsionadas por políticas de descarbonização e redução de custos das baterias. No Brasil, o segmento ainda está em fase inicial, mas registrou crescimento superior a 80% nas vendas entre 2022 e 2023, sinalizando uma tendência de adoção crescente (ABVE, 2024).

Nesse contexto, a autonomia de carga é apontada como um dos principais fatores que influenciam a decisão de compra e a experiência de uso dos veículos elétricos (MADZIEL; CAMPISI, 2023). A capacidade de prever com precisão o consumo energético a partir de variáveis operacionais em tempo real é, portanto, um problema de relevância prática e científica. Diferentemente dos motores de combustão interna, cujo comportamento pode ser

modelado por parâmetros mais estáveis, os veículos elétricos apresentam alta sensibilidade a fatores dinâmicos como velocidade, aceleração, regeneração de energia e condições do percurso (DI MARTINO et al., 2022).

Paralelamente, o comportamento do motorista constitui uma dimensão relevante na análise de dados veiculares. A identificação de padrões de condução a partir de dados operacionais é um problema de classificação com aplicações práticas em seguros veiculares, programas de condução eficiente e sistemas de assistência ao motorista (MOBINI SERAJI et al., 2025). Estudos mostram que é possível distinguir estilos de condução distintos — como conduta agressiva, moderada e econômica — de forma automatizada, com base em variáveis como aceleração, frenagem e velocidade média (RISTIANA et al., 2019).

Diante desse cenário, este trabalho aborda dois problemas sobre o mesmo conjunto de dados. Na primeira parte, serão aplicadas técnicas de aprendizado não supervisionado para classificar perfis de condução a partir dos dados do Vehicle Energy Dataset (VED). Na segunda parte, serão desenvolvidos e comparados modelos de regressão supervisionada para predição do consumo energético dos veículos. O trabalho está estruturado da seguinte forma: a Seção 2 apresenta os objetivos; a Seção 3 discute a fundamentação teórica; a Seção 4 descreve a metodologia; a Seção 5 apresenta os resultados esperados.

2. Objetivos

2.1. Objetivos Gerais

Aplicar técnicas de aprendizado de máquina ao Vehicle Energy Dataset (VED) para classificar perfis de condução por meio de clusterização e desenvolver modelos preditivos de consumo energético em veículos elétricos.

2.2. Objetivos Específicos

- Analisar a estrutura e as características do Vehicle Energy Dataset (VED), identificando variáveis relevantes para cada uma das duas tarefas propostas;
- Realizar o pré-processamento dos dados, incluindo tratamento de valores ausentes, remoção de ruídos e normalização;
- Construir atributos derivados representativos do comportamento de condução, como variação de velocidade, frequência de frenagem e padrões de aceleração;
- Aplicar algoritmos de clusterização para identificação e caracterização dos perfis de condução presentes no dataset, avaliando a coesão e separação dos grupos obtidos;
- Implementar e comparar modelos de regressão supervisionada — regressão linear, Random Forest e redes neurais artificiais — para predição do consumo energético;
- Avaliar o desempenho dos modelos preditivos por meio das métricas MAE, RMSE e R^2 , identificando qual abordagem apresenta melhor resultado para o problema proposto.

3. Fundamentação Teórica

3.1 Consumo Energético em Veículos Elétricos

O consumo energético em veículos elétricos resulta da interação entre fatores técnicos, ambientais e operacionais. Do ponto de vista técnico, a eficiência do motor elétrico, a capacidade da bateria e o sistema de frenagem regenerativa exercem influência direta sobre a demanda energética. Do ponto de vista externo, variáveis como a declividade da via, as condições de tráfego e a temperatura ambiente também afetam o consumo de forma significativa (DI MARTINO et al., 2022). Madziel e Campisi (2023) complementam essa visão ao demonstrar, com base em dados de campo, que o consumo real de veículos elétricos pode divergir em até 40% dos valores declarados pelos fabricantes em condições urbanas de uso intenso.

Uma revisão sistemática conduzida por Di Martino et al. (2022) categoriza as estratégias de modelagem do consumo energético em três abordagens: modelos físicos baseados em equações cinemáticas, modelos estatísticos e modelos baseados em aprendizado de máquina. Os autores concluem que abordagens baseadas em dados apresentam vantagens em cenários de alta variabilidade, onde as relações entre variáveis são não lineares e difíceis de modelar analiticamente — exatamente o caso do comportamento em tráfego urbano real.

3.2 Predição de Consumo com Aprendizado de Máquina

A aplicação de algoritmos de aprendizado de máquina à predição de consumo energético veicular tem crescido de forma expressiva na literatura recente. Achariyaviriya et al. (2023) avaliaram diferentes abordagens para estimativa de consumo em veículos elétricos utilizando dados de sensores embarcados, com destaque para modelos de Gradient Boosting e redes neurais, que obtiveram resultados superiores aos modelos físicos tradicionais especialmente em condições urbanas de tráfego variável. Os autores apontam que a granularidade temporal dos dados de entrada é um fator crítico: modelos treinados com amostras de 1 Hz apresentaram desempenho consistentemente superior aos treinados com dados agregados por minuto.

Em um estudo comparativo mais amplo, Hussain et al. (2025) avaliaram sete algoritmos aplicados à predição de consumo energético em veículos elétricos. Os resultados indicaram que o Random Forest obteve o melhor desempenho geral, com R^2 superior a 0,93 e RMSE reduzido em aproximadamente 38% em relação à regressão linear. Os autores destacam que a qualidade do pré-processamento e a seleção de atributos foram determinantes para a diferença de desempenho entre os algoritmos testados. Jui et al. (2024) reforçam essa perspectiva ao apontar que modelos com engenharia de atributos orientada ao comportamento operacional do veículo tendem a generalizar melhor para novos percursos.

3.3 Classificação de Perfis de Condução

A identificação de padrões de comportamento de motoristas a partir de dados veiculares é um problema bem estabelecido na literatura. Ristiana et al. (2019) demonstraram que variáveis como aceleração média, variação de velocidade e frequência de eventos bruscos

de frenagem são suficientes para distinguir estilos de condução com algoritmos de clusterização, obtendo separação estatística significativa entre grupos mesmo em datasets de dimensão reduzida. O algoritmo K-Means tem sido amplamente adotado nesse contexto pela sua eficiência computacional e pela interpretabilidade direta dos centróides resultantes (CHEN et al., 2023).

Uma revisão abrangente conduzida por Mobini Seraji et al. (2025), cobrindo mais de 120 trabalhos publicados entre 2015 e 2024, consolidou o estado da arte em técnicas de classificação comportamental de condutores. Os autores identificaram que a maioria dos estudos converge para três ou quatro perfis distintos — tipicamente denominados condução econômica, moderada e agressiva — e que esses perfis apresentam consistência estatística robusta quando derivados de janelas temporais superiores a cinco minutos. A revisão também destaca que métodos baseados em densidade, como o DBSCAN, têm ganhado espaço como alternativa ao K-Means em datasets com ruídos significativos. Chen et al. (2023), por sua vez, demonstraram que perfis derivados de dados de trajetória apresentam correlação significativa com indicadores de risco veicular, evidenciando a utilidade prática dessa classificação além da análise energética.

4. Metodologia

Este trabalho caracteriza-se como uma pesquisa aplicada de natureza experimental, baseada em dados reais de operação veicular. A metodologia está organizada em duas frentes independentes — classificação de perfis de condução e predição de consumo energético — que compartilham o mesmo dataset e as etapas iniciais de pré-processamento.

4.1. Tecnologias Utilizadas

Para o desenvolvimento deste trabalho, serão utilizadas ferramentas e tecnologias voltadas à análise de dados e aplicação de modelos de aprendizado de máquina. A linguagem de programação principal será o Python, devido à sua ampla utilização em projetos de ciência de dados e aprendizado de máquina.

Serão utilizadas bibliotecas específicas para manipulação e análise de dados, como Pandas e NumPy, além de bibliotecas para visualização, como Matplotlib e Seaborn. Para a implementação dos modelos de aprendizado de máquina, será utilizada a biblioteca Scikit-learn, que oferece suporte a diversos algoritmos de classificação e regressão. Caso necessário, também poderão ser utilizadas bibliotecas como TensorFlow ou Keras para implementação de redes neurais artificiais.

4.2. Arquitetura do Sistema

A metodologia proposta neste trabalho será dividida em etapas, desde a coleta dos dados até a avaliação dos modelos de aprendizado de máquina.

Inicialmente, será utilizado o Vehicle Energy Dataset (VED), que contém dados reais de operação de veículos, incluindo informações como velocidade, aceleração, latitude, longitude e consumo energético. Esses dados serão submetidos a uma etapa de pré-processamento, que inclui tratamento de valores ausentes, remoção de ruídos e normalização dos dados.

Na sequência, será realizada a etapa de engenharia de atributos, com o objetivo de extrair características relevantes relacionadas ao comportamento de condução, como variação de velocidade, padrões de aceleração e frequência de frenagem.

Posteriormente, será aplicada uma técnica de aprendizado não supervisionado, como o algoritmo K-Means, para identificação de perfis de condução. Esses perfis serão interpretados e classificados em categorias como condução agressiva, moderada ou econômica.

Em seguida, os perfis identificados serão incorporados como variáveis adicionais no conjunto de dados, sendo utilizados como entrada para os modelos de aprendizado supervisionado. Serão implementados diferentes algoritmos de regressão, como regressão linear, Random Forest e redes neurais artificiais, com o objetivo de prever o consumo energético dos veículos.

Por fim, os modelos serão avaliados utilizando métricas de desempenho como erro absoluto médio (MAE), raiz do erro quadrático médio (RMSE) e coeficiente de determinação (R^2). Também será realizada uma análise comparativa entre os modelos, bem como uma avaliação do impacto da inclusão dos perfis de condução na precisão das previsões.

4.3. Cronograma de Atividades

Tabela 1 - Cronograma de Atividades

	CRONOGRAMA DO TRABALHO FINAL DE CONCLUSÃO DE CURSO				
ETAPAS	AGO/2026	SET/2026	OUT/2026	NOV/2026	DEZ/2026
Levantamento bibliográfico	X				
Estudo do dataset (VED)	X				
Limpeza e tratamento de dados	X	X			
Engenharia de atributos		X			
Desenvolvimento (modelos ML)		X	X		
Clusterização (perfil)		X			
Integração dos modelos			X		
Testes e avaliação			X	X	
Escrita do artigo				X	
Revisão final				X	
Defesa do TCC					X

5. Resultados Esperados

Espera-se que o desenvolvimento deste trabalho permita a construção de modelos de aprendizado de máquina capazes de prever o consumo energético em veículos elétricos com boa precisão, utilizando dados reais de operação veicular. A partir da aplicação de diferentes algoritmos de regressão, como regressão linear, Random Forest e redes neurais

artificiais, espera-se identificar quais abordagens apresentam melhor desempenho na tarefa proposta.

Além disso, espera-se que a aplicação de técnicas de aprendizado não supervisionado possibilite a identificação de diferentes perfis de condução a partir dos dados do Vehicle Energy Dataset (VED). Esses perfis deverão representar padrões distintos de comportamento, como condução agressiva, moderada ou econômica, sendo obtidos a partir da análise de variáveis como velocidade e aceleração.

Outro resultado esperado é a verificação da influência dos perfis de condução na predição do consumo energético. Ao incorporar essas informações como variáveis adicionais nos modelos, espera-se observar melhorias nos indicadores de desempenho, como redução do erro absoluto médio (MAE) e da raiz do erro quadrático médio (RMSE), além do aumento do coeficiente de determinação (R^2).

Espera-se também que os resultados obtidos permitam uma análise comparativa entre os modelos implementados, possibilitando identificar quais técnicas são mais adequadas para o problema estudado. Essa análise poderá contribuir para a compreensão das relações entre comportamento de condução e consumo energético.

Por fim, espera-se que o trabalho contribua para o desenvolvimento de soluções voltadas à eficiência energética em veículos elétricos, fornecendo subsídios para futuras pesquisas e aplicações práticas no contexto de sistemas inteligentes e mobilidade elétrica.

6. Referências Bibliográficas

ACHARIYAVIRIYA, W.; et al.

Estimating Energy Consumption of Battery Electric Vehicles Using Vehicle Sensor Data and Machine Learning Approaches.

Energies, v. 16, n. 17, p. 6351, 2023.

Disponível em: [MDPI Energies Article](#)

HUSSAIN, Izhar; CHING, K. B.; UTTAPHAN, C.; TAY, K. G.; NOOR, A.

Evaluating machine learning algorithms for energy consumption prediction in electric vehicles: A comparative study.

Scientific Reports, v. 15, n. 1, p. 16124, 2025.

Disponível em: [Nature Scientific Reports Article](#)

KAKOUCHE, K.; et al.

Model predictive direct torque control and fuzzy logic energy management for multi power source electric vehicles.

Sensors, v. 22, n. 15, p. 5669, 2022.

Disponível em: [MDPI Sensors Article](#)

DI MARTINO, Andrea; MIRAFTABZADEH, Seyed Mahdi; LONGO, Michela.

Strategies for the modelisation of electric vehicle energy consumption: A review.

Energies, v. 15, n. 21, p. 8115, 2022.

Disponível em: [MDPI Energies Article](#)

MADZIEL, Maksymilian; CAMPISI, Tiziana.

Energy consumption of electric vehicles: Analysis of selected parameters based on created database.

Energies, v. 16, n. 3, p. 1437, 2023.

Disponível em: [MDPI Energies Article](#)

CHEN, S.; CHENG, K.; YANG, J.; ZANG, X.; LUO, Q.; LI, J.

Driving behavior risk measurement and cluster analysis driven by vehicle trajectory data.

Applied Sciences, v. 13, n. 9, p. 5675, 2023.

Disponível em: [MDPI Applied Sciences Article](#)

MOBINI SERAJI, M. H.; SHAFFIEE HAGHSHENAS, S.; SHAFFIEE HAGHSHENAS, S.; SIMIC, V.; PAMUCAR, D.; GUIDO, G.; ASTARITA, V.

A state-of-the-art review on machine learning techniques for driving behavior analysis: clustering and classification approaches.

Complex & Intelligent Systems, v. 11, n. 9, p. 386, 2025.

Disponível em: [Springer Article](#)

RISTIANA, R.; ROHMAN, A. S.; MACHBUB, C.; PURWADI, A.; RIJANTO, E.

A new approach of EV modeling and its control applications to reduce energy consumption.

IEEE Access, v. 7, p. 141209–141225, 2019.

Disponível em: [IEEE Xplore Article](#)

JUI, J. J.; AHMAD, M. A.; MOLLA, M. I.; RASHID, M. I. M.

Optimal energy management strategies for hybrid electric vehicles: A recent survey of machine learning approaches.

Journal of Engineering Research, v. 12, n. 3, p. 454–467, 2024.

Disponível em: [ScienceDirect Article](#)