



Predição de Consumo Energético e Classificação de Perfis de Condução em Veículos Elétricos Utilizando Aprendizado de Máquinas

Apresentação de Pré-Banca de Trabalho de Conclusão de Curso

Autor:	Danilo Carvalho de Oliveira
Orientador:	Prof. Me./Dr. Douglas Donizeti de Castilho Braz
Instituição:	IFSULDEMINAS - Campus Poços de Caldas




A Adoção em Massa



Mais de **40 milhões** de EVs em circulação globalmente (IEA, 2024).

Crescimento superior a **80%** nas vendas anuais no Brasil (ABVE, 2024).


O Gargalo Tecnológico



A **Ansiedade de Autonomia** permanece como a principal barreira na experiência do usuário.

O **Paradoxo Urbano**: O consumo real nas vias urbanas pode divergir em até **40%** das estimativas de fábrica (Madziel & Campisi, 2023).

A Complexidade do Consumo



Perguntas de Pesquisa

01.


É possível identificar perfis distintos de condução a partir de dados reais de operação veicular utilizando técnicas de aprendizado de máquinas?

02.


Quais variáveis apresentam a maior influência na estimativa do consumo energético dos veículos em cenários de tráfego real?

Objetivo Geral

Aplicar técnicas avançadas de Machine Learning para extrair padrões do caos operacional.



Dados Brutos




**Motor de
Machine
Learning**



Pilar 1: Identificar e classificar perfis de condução
(Clusterização Não Supervisionada)

Pilar 2: Desenvolver modelos preditivos de alta precisão para o consumo
(Regressão Supervisionada)


Objetivos Específicos: A Progressão Metodológica



Justificativa Teórica: Modelos Físicos vs. Machine Learning


		Modelos Físicos/Cinemáticos	Modelos Baseados em Dados (ML)
Dados Utilizados		Baseados em equações e condições controladas.	Dados reais de condução e consumo energético.
Representação do Problema		Dificuldade em modelar relações complexas entre variáveis.	Captura padrões não lineares e interações entre múltiplos fatores.
Precisão das Previsões		Dependem de hipóteses e simplificações do sistema.	Aprendem padrões diretamente dos dados e realizam previsões mais precisas.

Perfis de Condução Esperados




Econômico

Otimização de inércia e acelerações suaves.



Moderado

Padrão basal de condução urbana diária.




Agressivo

Acelerações bruscas e frenagens severas.

Consenso da Literatura: Variáveis-chave incluem aceleração média, variação de velocidade e eventos de frenagem.

- **Algoritmos dominantes:** K-Means (eficiência de centróides) e DBSCAN (isolamento de ruídos) (Mobini Seraji et al., 2025).

A Matéria-Prima: Vehicle Energy Dataset (VED)



Posicionamento (GPS):
Latitude, Longitude,
Distância, Tempo.


Cinemática (OBD):
Velocidade instantânea,
Aceleração.

Energia:
Consumo real da
bateria (A âncora do
modelo preditivo).


Relevância Estratégica do VED:

A Chave para a Modelagem: O VED é fundamental por fornecer dados reais de condução e consumo energético, possibilitando a identificação de perfis de motoristas e a construção de modelos preditivos mais confiáveis e aplicáveis ao mundo real.

Stack Tecnológico e Ferramental



Arquitetura do Sistema: O Fluxo Metodológico



Insight Chave: O agrupamento não supervisionado alimenta e enriquece os dados de entrada do modelo supervisionado.

Abordagem Proposta: Abordagem Híbrida

Descoberta de Padrões (Não Supervisionado)

Objetivo: Traduzir telemetria bruta em categorias de comportamento de condução.

Algoritmo Principal: K-Means
(agrupamento iterativo baseado em centróides).

Saída: Labels categóricos (Econômico, Moderado, Agressivo).

Predição de Consumo (Supervisionado)

Objetivo: Mapear variáveis de tráfego e perfil comportamental para estimar o kW/h.

Baseline: Regressão Linear.

Modelos Avançados: Random Forest Regressor (Ensemble) e MLP Regressor (Redes Neurais Artificiais).

Cronograma de Execução (2026)

	AGO	SET	OUT	NOV	DEZ
Estudo do Dataset (VED) e Bibliografia					
Limpeza, Tratamento e Eng. de Atributos					
Desenvolvimento ML e Clusterização					
Integração, Testes e Avaliação					
Escrita do Artigo e Revisão					
Defesa do TCC					

Resultados Esperados e Critérios de Sucesso



Predição do Consumo Energético

Desenvolvimento de modelos capazes de prever o consumo energético de veículos elétricos fazendo uma comparação entre Regressão Linear, Random Forest e Redes Neurais.



Identificação de Perfis de Condução

Aplicação de técnicas de clusterização no VED para classificação de perfis como agressivo, moderado e econômico.



Avaliação da Influência dos Perfis

Inclusão dos perfis de condução nos modelos preditivos fazendo uma análise do impacto em métricas como MAE, RMSE e R^2 .



Contribuições do Trabalho

Comparar diferentes técnicas de aprendizado de máquinas e apoio ao desenvolvimento de soluções para eficiência energética.

Obrigado pela atenção.
Apto para arguição da banca

